Etapa 1 – Análise exploratória da base NSL-KDD

Trabalho em Competição de IA · Grupo 3 · Base oficial do Canvas (treino.csv, 69.833 registros)

Davi Lucas Dias Morais · Gabriel Marques Fantini · Julia Nathalia Sebastião Pinto · Thiago Tavares Willcox Noronha · Túlio Geraldo da Costa Silva

1. Caracterização da base

O treino tem 49 atributos de entrada e a classe *class* (*normal* ou *anomaly*). Além dos 41 atributos descritivos do NSL-KDD, há 8 colunas extras (*src_bytes_kb*, *dst_bytes_kb*, *total_bytes*, *same_srv_pct*, *protocolo_cod*, *score_ids_legado*, *tipo_alerta_soc* e *tempo_resposta_analista_min*). A coluna *difficulty* citada no enunciado não existe nos arquivos. O teste tem 24.333 registros, com a coluna *id* e sem a classe.

2. Classes e desbalanceamento

normal: 65.754 registros (94,16%). *anomaly*: 4.079 registros (5,84%). A base é binária e fortemente desbalanceada, de modo que a acurácia não é uma métrica adequada; usaremos F1-macro.

3. Atributos categóricos

protocol_type: 3 categorias após normalizar caixa (tcp, udp, icmp). *service*: 67 categorias, com 4.416 ausências. *flag*: 11 categorias, com 4.093 vazios. *tipo_alerta_soc*: OK e ALERTA. A alta cardinalidade de *service* exige cuidado na codificação.

4. Inconsistências

(a) Categorias que diferem só pela caixa: tcp/TCP, SF/sf, REJ/rej, S0/s0, entre outras. (b) Valores negativos: 358 durações (mínimo de −1.308.801) e 189 valores de *src_bytes*. (c) Frações fora de [0, 1] em 3.368 registros. (d) *su_attempted* assume o valor 2, fora da definição binária original (0 ou 1): são 49 registros, todos *normal*, com root_shell e num_root altos. (e) *num_outbound_cmds* é constante (zero). (f) 28 atributos têm ausências; os maiores são tempo_resposta_analista_min (91,37%), src_bytes (39,96%) e dst_host_srv_count (39,87%).

5. Redundâncias

Cinco colunas são determinísticas em relação a outras, confirmadas em todas as linhas comparáveis: *src_bytes_kb* = src_bytes / 1024; *dst_bytes_kb* = dst_bytes / 1024; *total_bytes* = src_bytes + dst_bytes; *same_srv_pct* = 100 × same_srv_rate; *protocolo_cod* é codificação de protocol_type. Além disso, 3.730 registros pertencem a grupos com entradas idênticas e classes diferentes (conflitos), o que corresponde a 46,48% das anomalias. Essa retirada não foi adotada nesta etapa.

6. Possíveis problemas de vazamento

Três atributos têm associação forte com a classe e origem não documentada. *score_ids_legado*: correlação de Pearson 0,573. *tipo_alerta_soc*: V de Cramér 0,728, com 67% das linhas ALERTA sendo anomalias. *tempo_resposta_analista_min*: presente em 76,5% das anomalias e em 4,4% dos normais. Associação alta não comprova vazamento, mas a disponibilidade desses valores no momento da detecção precisa ser confirmada. Por precaução, os três ficam fora dos experimentos até essa confirmação.

7. Pendências

Confirmar com a professora a ausência de *difficulty* e a origem e disponibilidade dos três atributos suspeitos. Definir o tratamento de *su_attempted = 2*, dos valores negativos e das frações fora do domínio, comparando estratégias nas etapas seguintes.

8. Link

link do colab