Etapa 2 - Pré-processamento da base NSL-KDD

Trabalho em Competição de IA · Grupo 3 · Base oficial do Canvas (treino.csv, 69.833 registros)

Davi Lucas Dias Morais · Gabriel Marques Fantini · Julia Nathalia Sebastião Pinto · Thiago Tavares Willcox Noronha · Túlio Geraldo da Costa Silva

1. Base e validação

A comparação usou o treino oficial e **F1-macro** como métrica principal, com recall de *anomaly* como complemento. Registros com as mesmas entradas ficaram juntos. Quatro divisões serviram para comparar técnicas e a quinta, com 13.883 registros e 788 anomalias, ficou reservada nesta rodada para conferir as combinações. Os ajustes ocorreram apenas na parcela de treino de cada divisão. O teste oficial ficou reservado para a entrega final.

2. Redundâncias e inconsistências

As versões A, B e C obtiveram F1-macro de 0,8544, 0,8544 e 0,8543, respectivamente, na árvore de referência. Escolhemos a versão C, com 40 atributos antes da codificação, após retirar as cinco colunas derivadas. Durações e bytes negativos e taxas fora do intervalo de 0 a 1 foram tratados como ausentes. Retirar duplicatas de mesmo rótulo reduziu cerca de 16% das linhas de ajuste. Preservamos os grupos conflitantes, pois sua retirada reduziu o recall de anomalias de 70,64% para 69,13%.

3. Imputação e codificação

Na árvore, o KNN numérico obteve 0,8570 de F1-macro, frente a 0,8543 da mediana e 0,8553 da média. O KNN usou cinco vizinhos e 2.000 referências amostradas do treino. A codificação inteira atingiu 0,8579 e o one-hot completo, 0,8543. Com 67 categorias em *service*, testamos agrupar as raras. Na reserva, isso reduziu as entradas de 118 para 95 e o F1-macro da árvore deduplicada de 0,8583 para 0,8537. A melhor combinação da rede usou mediana, categoria explícita para ausências e one-hot completo.

4. Transformação numérica

Na rede, o Z-score obteve F1-macro médio de **0,8386**, à frente de Min-Max (0,8353), escala robusta (0,8000) e ausência de escala (0,7547). Foi a melhor transformação nas quatro divisões desse experimento.

5. Balanceamento de classes

A árvore obteve F1-macro de 0,8543 sem balanceamento, 0,8499 com sobreamostragem aleatória e 0,8261 com subamostragem aleatória. Os dois métodos usaram uma anomalia para dois registros normais. A sobreamostragem elevou o recall de anomalias da árvore de 70,64% para 78,81%, com perda em F1-macro. Na rede, ela favoreceu a melhor combinação avaliada.

6. Redução de dimensionalidade

Na árvore, o PCA com 60 componentes obteve F1-macro de 0,8533 e o filtro de 60 entradas, 0,8359. Como a referência com todas as colunas ficou em 0,8543, as duas combinações propostas seguem sem redução adicional.

7. Combinações escolhidas para a Etapa 3

As duas configurações usam versão C, deduplicação de mesmo rótulo no ajuste e Z-score. A média vem das quatro divisões iniciais. A reserva é a quinta divisão, que já havia integrado o piloto anterior.

Configuração	F1-macro médio	F1-macro na reserva	Recall de anomaly na reserva
Árvore com KNN, moda, códigos inteiros e sem balanceamento	0,8592	0,8624	72,84%
Rede com mediana, ausência explícita, one-hot e sobreamostragem	0,8430	0,8502	79,44%

A árvore teve o melhor F1-macro entre as combinações testadas. A rede detectou mais anomalias na reserva. As duas serão reavaliadas na comparação de classificadores da Etapa 3.

8. Link

Link do colab