RELATÓRIO DE ANÁLISE EXPLORATÓRIA

Detecção de intrusão em redes

Base oficial NSL-KDD | Etapa 1 | 01/11/2026

Disciplina: Inteligência Artificial | **Professora:** Cristiane Neri Nobre

Grupo no Canvas: Trabalho prático 3

Davi Lucas Dias Morais
Julia Nathalia Sebastiao Pinto
Túlio Geraldo da Costa Silva
Gabriel Marques Fantini
Thiago Tavares Willcox Noronha

Repositório: github.com/JuliaSebastiao/nsl-kdd-intrusion-detection

Notebook: Abrir 01_analise_exploratoria.ipynb no GitHub
Branch da versão analisada: **feat/preprocessamento-etapa2**.

REGISTROS	ATRIBUTOS DE ENTRADA	CLASSE ANOMALY
69.833	49	5,84%

1. Base utilizada e alcance da análise

Foi analisado exclusivamente o arquivo **treino.csv** fornecido no Canvas, com o alvo binário **class** (**normal** ou **anomaly**). O CSV contém os 41 atributos originais e oito adicionais, totalizando 49 entradas. Não contém **difficulty**, embora esse campo apareça na descrição geral do enunciado.

Esta etapa caracteriza a base e seus problemas. Nenhum registro ou atributo foi retirado da análise; não foram aplicados imputação, codificação das entradas, balanceamento ou treinamento de classificadores. Os atributos do teste não foram usados para calcular as estatísticas ou escolher tratamentos.

2. Classes e desbalanceamento

Classe	Registros	Percentual
normal	65.754	94,16%
anomaly	4.079	5,84%

A predominância de **normal** exige atenção à classe minoritária. Na avaliação posterior, a acurácia isolada pode esconder falhas na detecção de anomalias; a métrica oficial é F1-macro. Não há resultados de classificação nesta etapa.

3. Entradas nominais

Atributo	Categorias originais	Após comparar caixa/espaços
protocol_type	6	3
service	96	67
flag	19	11

Contagens sem valores ausentes. A comparação ignorando caixa e espaços laterais foi temporária; a base original foi preservada. **protocolo_cod** também é nominal: seus números identificam protocolos, sem impor ordem ou distância. A escolha e a aplicação da codificação ficam para a Etapa 2.

Qualidade, redundâncias e conflitos

4. Dados ausentes e valores a investigar

28 atributos possuem ausências. O maior percentual está em **tempo_resposta_analista_min**. Os seis atributos com mais valores ausentes são:

Atributo	Ausentes	Percentual
tempo_resposta_analista_min	63.804	91,37%
src_bytes_kb	27.906	39,96%
total_bytes	27.906	39,96%
src_bytes	27.906	39,96%
dst_host_srv_count	27.844	39,87%
dst_host_serror_rate	21.393	30,63%

Ocorrência observada	Quantidade
Durações negativas	358
Valores negativos em src_bytes	189
Registros com ao menos uma fração *_rate fora de [0, 1]	3.368
Registros com su_attempted = 2, a esclarecer	49

Os conjuntos acima podem se sobrepor. O valor 2 de **su_attempted** precisa de esclarecimento antes de recodificar ou excluir registros. Valores de contadores acima das referências herdadas de 511 ou 255 não foram classificados automaticamente como erros: não há confirmação de que sejam limites obrigatórios da base modificada. Extremos podem representar eventos legítimos.

5. Redundâncias

num_outbound_cmds é constante, com valor zero. Também foram verificadas as relações abaixo nas linhas comparáveis; todas apresentaram correspondência total:

Atributo derivado	Relação confirmada
src_bytes_kb	src_bytes / 1024
dst_bytes_kb	dst_bytes / 1024
total_bytes	src_bytes + dst_bytes
same_srv_pct	same_srv_rate * 100
protocolo_cod	Codificação determinística de protocol_type

6. Duplicatas e classes conflitantes

11.355 repetições excedentes de linhas completas foram identificadas. Há também **3.730 registros** em **1.702 grupos** de entradas iguais com classes diferentes. Essas contagens se sobrepõem e não devem ser somadas. O impacto hipotético da retirada de todos os conflitos seria:

Classe	Registros envolvidos	Percentual da classe
normal	1.834	2,79%
anomaly	1.896	46,48%

A retirada atingiria **46,48% das anomalias**, portanto não foi adotada automaticamente. Igualdade nos campos observados e no padrão de ausência não comprova que os registros representem o mesmo evento real. Duplicatas também exigem cuidado na futura construção dos grupos de validação.

Associações e limites das conclusões

7. Investigação de possível vazamento

Os 49 atributos foram examinados em relação à classe: Pearson para entradas numéricas (normal = 0, anomaly = 1) e V de Cramér para nominais, incluindo **protocolo_cod**. A correlação de uma constante é indefinida. As medidas têm interpretações diferentes e não são um filtro automático de seleção.

Atributo sob investigação	Evidência descritiva
score_ids_legado	Pearson com a classe: 0,573. Há sobreposição das distribuições.
tipo_alerta_soc	V de Cramér: 0,728. Existem alertas em normal e registros anomaly com OK.
tempo_resposta_analista_min	Ausente em 95,57% de normal e 23,54% de anomaly.

Esses padrões motivam verificar **como e quando** os sinais foram produzidos. Associação alta não comprova vazamento; associação baixa não elimina utilidade não linear. O processo de geração não foi documentado. As três colunas permanecem no diagnóstico e ficam provisoriamente fora dos futuros experimentos, até confirmar sua disponibilidade antes da previsão.

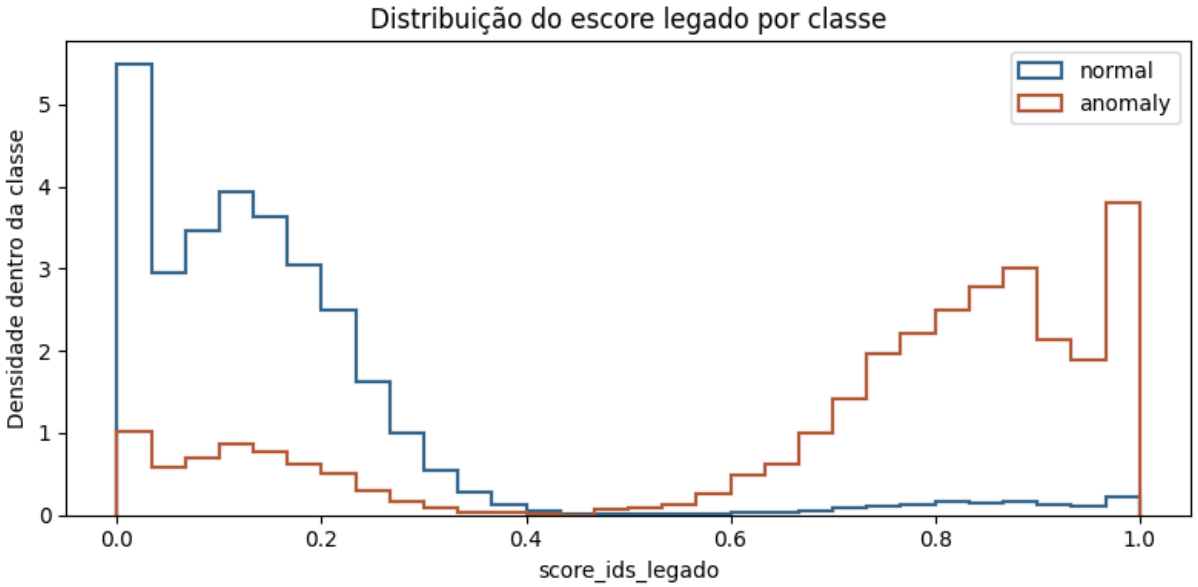


Figura 1. Distribuição de score_ids_legado no treino. As curvas foram normalizadas dentro de cada classe; a separação parcial não demonstra a origem temporal do atributo.

8. Continuidade e reprodução

As próximas comparações devem tratar ausências, inconsistências, redundâncias e conflitos, preservando a classe minoritária. Foram planejadas três representações, com 45, 41 ou 40 atributos antes da codificação. Não foi escolhido um tratamento vencedor. O ajuste do pré-processamento será restrito às parcelas de treino da validação interna.

O notebook do link da primeira página usa **preprocessamento.py** e **data/raw/treino.csv**. As instruções e versões das bibliotecas estão no README e em requirements.txt. Foram aprovados **10 testes**; o notebook modular e a cópia com funções incluídas executaram sem erros, com o mesmo diagnóstico e os mesmos **9 gráficos**. O treino permaneceu intacto. Os CSVs não estão no GitHub.

Fontes: treino.csv e enunciado atualizado disponibilizados pela disciplina no Canvas; definições dos atributos KDD; scikit-learn: prevenção de vazamento.

Apoio de IA generativa: ChatGPT/Codex auxiliou na organização do diagnóstico, na implementação e depuração de código e na redação. As estatísticas foram verificadas por execução e testes.