PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Curso de Ciência da Computação
Trabalho Prático 3

Davi Lucas Dias Morais
Gabriel Marques Fantini
Julia Nathalia Sebastiao Pinto
Thiago Tavares Willcox Noronha
Túlio Geraldo da Costa Silva

DETECÇÃO DE INTRUSÃO EM REDES:
análise exploratória e diagnóstico da base oficial NSL-KDD

Belo Horizonte
2026

Davi Lucas Dias Morais
Gabriel Marques Fantini
Julia Nathalia Sebastiao Pinto
Thiago Tavares Willcox Noronha
Túlio Geraldo da Costa Silva

DETECÇÃO DE INTRUSÃO EM REDES:
análise exploratória e diagnóstico da base oficial NSL-KDD

Relatório da primeira etapa do Trabalho Prático 3, apresentado à disciplina Inteligência Artificial do curso de Ciência da Computação da Pontifícia Universidade Católica de Minas Gerais, como parte da avaliação da disciplina.

Professora: Cristiane Neri Nobre.

Belo Horizonte
2026

SUMÁRIO

1 INTRODUÇÃO 3

1.1 Base e classes 3

1.2 Entradas nominais 3

2 DIAGNÓSTICO DA QUALIDADE DOS DADOS 4

2.1 Ausências e inconsistências 4

2.2 Redundâncias 5

2.3 Duplicatas e conflitos 5

3 INVESTIGAÇÃO DE POSSÍVEL VAZAMENTO 6

4 CONSIDERAÇÕES FINAIS E REPRODUÇÃO 7

4.1 Reprodução dos resultados 7

4.2 Apoio de ferramentas de inteligência artificial 7

REFERÊNCIAS 8

1 INTRODUÇÃO

Este relatório caracteriza o treino oficial da competição de detecção de intrusão em redes e identifica inconsistências, redundâncias e possíveis vazamentos (Nobre, 2026).

Utilizou-se somente treino.csv, fornecido no Canvas. Não houve imputação, codificação das entradas, balanceamento, remoção de registros ou treinamento de modelos. Os atributos do teste não foram usados para calcular estatísticas ou escolher tratamentos.

1.1 Base e classes

O treino possui 69.833 registros, 49 entradas (41 originais e oito adicionais) e o alvo class, com normal e anomaly. O campo difficulty, citado no enunciado, não consta no CSV. A Tabela 1 apresenta a distribuição das classes.

Tabela 1 - Distribuição das classes

Classe	Registros	Percentual
normal	65.754	94,16%
anomaly	4.079	5,84%

Fonte: Elaborado pelos autores (2026).

A predominância de normal exige acompanhar a classe minoritária. A acurácia isolada pode esconder falhas na detecção de anomalias; a métrica oficial é F1-macro (Nobre, 2026). Não há resultados de classificação nesta etapa.

1.2 Entradas nominais

protocol_type, service e flag não têm ordem (University of California, Irvine, 1999). protocolo_cod também é nominal, apesar dos códigos numéricos. A Tabela 2 compara categorias ignorando caixa e espaços, sem alterar a base. A codificação será avaliada na Etapa 2.

Tabela 2 - Categorias observadas nas entradas nominais

Atributo	Categorias originais	Após comparação
protocol_type	6	3
service	96	67
flag	19	11

Fonte: Elaborado pelos autores (2026).
Nota: Contagens sem valores ausentes.

2 DIAGNÓSTICO DA QUALIDADE DOS DADOS

As verificações de domínio, ausências e redundâncias descrevem problemas a investigar. Não constituem critérios automáticos de correção ou exclusão.

2.1 Ausências e inconsistências

28 atributos possuem ausências. O maior percentual está em tempo_resposta_analista_min. Os seis atributos com mais valores ausentes são apresentados na Tabela 3.

Tabela 3 - Atributos com maior quantidade de ausências

Atributo	Ausentes	Percentual
tempo_resposta_analista_min	63.804	91,37%
src_bytes_kb	27.906	39,96%
total_bytes	27.906	39,96%
src_bytes	27.906	39,96%
dst_host_srv_count	27.844	39,87%
dst_host_serror_rate	21.393	30,63%

Fonte: Elaborado pelos autores (2026).

Também foram observados valores negativos e frações fora do domínio esperado, resumidos na Tabela 4. Os conjuntos de registros podem se sobrepor.

Tabela 4 - Principais ocorrências a investigar

Ocorrência	Quantidade
Durações negativas	358
Valores negativos em src_bytes	189
Registros com ao menos uma fração *_rate fora de [0, 1]	3.368
Registros com su_attempted = 2, a esclarecer	49

Fonte: Elaborado pelos autores (2026).

O valor 2 de su_attempted precisa de esclarecimento antes de qualquer recodificação. Contadores acima das referências herdadas de 511 ou 255 não foram classificados automaticamente como erros: não há confirmação de que esses sejam limites obrigatórios da base modificada. Extremos também podem representar eventos legítimos.

2.2 Redundâncias

num_outbound_cmds é constante, com valor zero. As relações do Quadro 1 foram confirmadas em todas as linhas comparáveis. Os atributos foram preservados no diagnóstico.

Quadro 1 - Relações determinísticas verificadas

Atributo derivado	**Relação confirmada**
src_bytes_kb	src_bytes / 1024
dst_bytes_kb	dst_bytes / 1024
total_bytes	src_bytes + dst_bytes
same_srv_pct	same_srv_rate * 100
protocolo_cod	Codificação determinística de protocol_type

Fonte: Elaborado pelos autores (2026).

2.3 Duplicatas e conflitos

Foram identificadas 11.355 repetições excedentes de linhas completas e 3.730 registros em 1.702 grupos de entradas iguais com classes diferentes. Essas contagens se sobrepõem e não devem ser somadas. A Tabela 5 apresenta o impacto hipotético da retirada de todos os registros conflitantes.

Tabela 5 - Impacto hipotético da retirada dos conflitos

Classe	**Registros envolvidos**	**Percentual da classe**
normal	1.834	2,79%
anomaly	1.896	46,48%

Fonte: Elaborado pelos autores (2026).

A retirada atingiria 46,48% das anomalias e, por isso, não foi adotada automaticamente. Igualdade nos campos observados e no padrão de ausência não comprova que os registros representem o mesmo evento real. Duplicatas também precisam ser consideradas na futura construção dos grupos de validação.

3 INVESTIGAÇÃO DE POSSÍVEL VAZAMENTO

Os 49 atributos foram examinados em relação à classe: Pearson para entradas numéricas (normal = 0 e anomaly = 1) e V de Cramér para nominais, incluindo protocolo_cod. A correlação de uma constante é indefinida. As medidas têm interpretações diferentes e não constituem um filtro automático de seleção. O Quadro 2 reúne os principais sinais sob investigação.

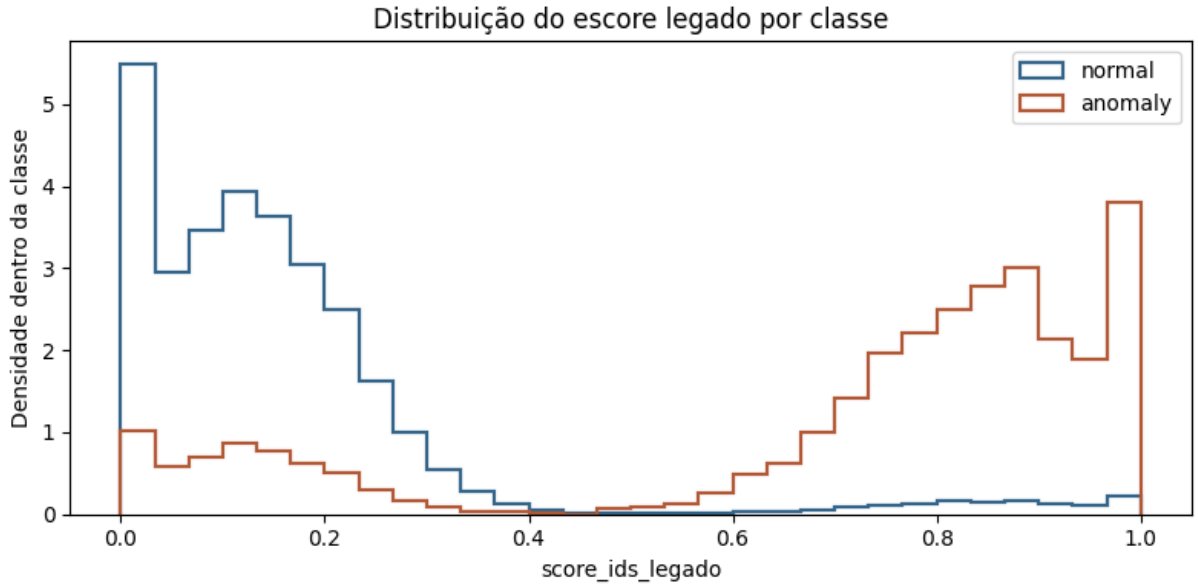
Quadro 2 - Evidências descritivas das colunas sob investigação

Atributo	**Evidência**
score_ids_legado	Pearson: 0,573. Há sobreposição das distribuições.
tipo_alerta_soc	V de Cramér: 0,728. Existem alertas em normal e registros anomaly com OK.
tempo_resposta_analista_min	Ausente em 95,57% de normal e 23,54% de anomaly.

Fonte: Elaborado pelos autores (2026).

Esses padrões motivam verificar como e quando os sinais foram produzidos. Associação alta não comprova vazamento; associação baixa não elimina utilidade não linear. A origem não foi documentada. As três colunas permanecem no diagnóstico e ficam provisoriamente fora dos futuros experimentos, até confirmar sua disponibilidade antes da previsão.

Gráfico 1 - Distribuição do escore legado por classe



Fonte: Elaborado pelos autores (2026).
Nota: As curvas foram normalizadas dentro de cada classe. A separação parcial não demonstra a origem temporal do atributo.

4 CONSIDERAÇÕES FINAIS E REPRODUÇÃO

Os achados orientam os experimentos de pré-processamento, mas ainda não sustentam um tratamento ou modelo vencedor. As próximas comparações devem tratar ausências, inconsistências, redundâncias e conflitos, preservando a classe minoritária. Foram planejadas três representações, com 45, 41 ou 40 atributos antes da codificação.

O ajuste do pré-processamento será restrito às parcelas de treino da validação interna. A separação entre treino e validação e a reutilização das transformações aprendidas seguem as recomendações de prevenção de vazamento da documentação do scikit-learn (Scikit-learn developers, 2026).

4.1 Reprodução dos resultados

O código e o notebook estão no repositório público do projeto (Morais et al., 2026). O link abaixo aponta diretamente para a versão analisada, na branch feat/preprocessamento-etapa2:

https://github.com/JuliaSebastiao/
nsl-kdd-intrusion-detection/blob/
feat/preprocessamento-etapa2/
01_analise_exploratoria.ipynb

Para reproduzir a análise, devem ser utilizados preprocessamento.py e o arquivo oficial data/raw/treino.csv, seguindo as instruções do README e as versões indicadas em requirements.txt. Os CSVs não estão no GitHub.

Os 10 testes de diagnóstico passaram. O notebook modular e a cópia com funções incluídas executaram sem erros, com o mesmo diagnóstico e os mesmos nove gráficos. O treino permaneceu intacto.

4.2 Apoio de ferramentas de inteligência artificial

ChatGPT/Codex auxiliou na organização do diagnóstico, na implementação e depuração de código e na redação do relatório. As estatísticas foram verificadas por execução e testes, conforme a declaração de apoio prevista na atividade (Nobre, 2026).

REFERÊNCIAS

MORAIS, Davi Lucas Dias; FANTINI, Gabriel Marques; PINTO, Julia Nathalia Sebastiao; NORONHA, Thiago Tavares Willcox; SILVA, Túlio Geraldo da Costa. **NSL-KDD: detecção de intrusão em redes**. 2026. Repositório de código. Disponível em: https://github.com/JuliaSebastiao/nsl-kdd-intrusion-detection. Acesso em: 1 nov. 2026.

NOBRE, Cristiane Neri. **Trabalho em competição: detecção de intrusão em redes**. Belo Horizonte: PUC Minas, 2026. Enunciado e arquivos oficiais disponibilizados no Canvas para a disciplina Inteligência Artificial.

SCIKIT-LEARN DEVELOPERS. **Common pitfalls and recommended practices**. Scikit-learn documentation, 2026. Disponível em: https://scikit-learn.org/stable/common_pitfalls.html. Acesso em: 1 nov. 2026.

UNIVERSITY OF CALIFORNIA, IRVINE. **KDD-CUP-99 task description**. Irvine, 1999. Disponível em: https://kdd.ics.uci.edu/databases/kddcup99/task.html. Acesso em: 1 nov. 2026.